

Цифровая обработка сигнала и распознавание речи



Елизавета Лазарева


О чем поговорим

- Введение в ЦОС, как представлен звук в памяти компьютера
- Распознавание речи ASR (какую задачу решаем, как оцениваем качество решения)
- Архитектуры моделей для решения задачи ASR (рассмотрим основные подходы, подробнее поговорим про SOTA решения)
- Self-Supervised Learning в задаче ASR
- Применение LM для улучшения качества распознавания


Мотивация

- Применение ASR:
 - Умные колонки: Маруся, Алиса, и т.д.
 - Колл-центры – автоматизация и снижение нагрузки на бизнес
 - Помощники: ChatGPT аудио-чат
- Область быстро развивается, появляются новые методы
- ASR идет рука об руку с LLM


Что такое звук?



Звук (вспомним физику)





©2011. Dan Russell



Звуковая волна (звуковые колебания) — это передающиеся в пространстве механические колебания молекул вещества (например, воздуха).

Дискретизация и квантование сигнала



массив значений
(многомерный вектор)
сложно анализировать

Преобразование Фурье

$$u(x) = \int_{-\infty}^{+\infty} U(f) e^{2\pi i f x}, \quad U(f) = \int_{-\infty}^{+\infty} u(x) e^{-2\pi i f x} dx$$

обратное

прямое





Фурье-преобразование
раскладывает сигнал на набор
гармонических колебаний.
Подробнее [тут](#) и [тут](#).

Преобразование Фурье: пример

$$f(t) = A \cos(\omega_0 t)$$

$$F(\omega) = \pi A [\delta(\omega - \omega_0) + \delta(\omega + \omega_0)]$$



Фурье-образ $F(\omega)$ — комплексная функция.

На каждой частоте ω она даёт комплексное число, которое описывает вклад этой частоты в исходный сигнал.


Преобразование Фурье

$$A(\omega) = |F(\omega)|$$


Амплитуда (модуль) показывает, сколько энергии у частоты ω в сигнале.

$$\varphi(\omega) = \arg F(\omega)$$

Фаза (аргумент) показывает, на сколько сдвинута по времени данная синусоида.





Теорема Котельникова (Найквиста-Шеннона)





Любой аналоговый сигнал с максимальной частотой F может быть точно восстановлен по дискретным отсчетам, если частота семплирования F_s удовлетворяет условию:

$$F_s > 2F$$

Достаточно ли просто знать спектр сигнала?





Достаточно ли просто знать спектр сигнала?



Спектр у этих двух сигналов - **одинаковый!**
Как учесть временную составляющую данных?


Спектрограмма (Short-Time Fourier Transform)




Спектрограмма (STFT). Mel шкала

$$m[mel] = 1127 \ln\left(1 + \frac{f[Hz]}{700}\right)$$

← Шкала частот (имитирует чувствительность человеческого уха)



Мел спектрограмма




Чанки спектрограммы (последовательность)


Итоги: что важно запомнить по ЦОС

- При оцифровывании аналогового сигнала делаются **дискретизация и квантование**
- При слишком низкой частоте дискретизации в спектре появляются ложные частоты (**алиасинг**). Чтобы с этим бороться – **теорема Котельников**
- При анализе, как меняются частоты во времени, используют **спектрограмму** — считаем Фурье в скользящем окне и получаем картинку время × частота.
- При работе с речью в нейросетях вместо обычного спектра почти всегда используют **log-Mel спектрограмму**

Automatic Speech Recognition: метрики качества



Постановка задачи Automatic Speech Recognition



Как оценить качество "перевода"?

Метрики оценки качества транскрибации

Word Error Rate

S — substitutions: замены слов

I — insertions: вставки лишних слов

D — deletions: пропуски слов

N — reference words

$$WER = \frac{S + I + D}{N}$$

Какая доля слов распознана
неправильно?

ref = "по дороге домой услышал скрип"

hypo = "а по дороге услышал стук"

	I		C		C		D		C		S	
	%		по		дороге		домой		услышал		скрип	
	а		по		дороге		#		услышал		стук	

Метрики оценки качества транскрибации

Word Error Rate

- S** — substitutions: замены слов
- I** — insertions: вставки лишних слов
- D** — deletions: пропуски слов
- N** — reference words

$$WER = \frac{S + I + D}{N}$$

Какая доля слов распознана неправильно?

Также, существуют:

- CER - character error rate;
- SER - sentence error rate;

По возрастанию строгости метрик: CER-WER-SER

Различаются только юнитами: символы-слова-предложения

Считаем с помощью [алгоритма](#) поиска редакционного расстояния

Метрики оценки качества транскрибации

Word Error Rate

S — substitutions: замены слов

I — insertions: вставки лишних слов

D — deletions: пропуски слов

N — reference words

$$WER = \frac{S + I + D}{N}$$

Может ли WER быть > 1?

Также, существуют:

- CER - character error rate;
- SER - sentence error rate;

По возрастанию строгости метрик: CER-WER-SER

Различаются только юнитами: символы-слова-предложения

Метрики оценки качества транскрибации

Word Error Rate

S — substitutions: замены слов

I — insertions: вставки лишних слов

D — deletions: пропуски слов

N — reference words

$$\text{WER} = \frac{S + I + D}{N}$$

Как считать?


Какая сложность?

ref = "по дороге домой услышал скрип"

hypo = "а по дороге услышал стук"

	I		C		C		D		C		S	
	%		по		дороге		домой		услышал		скрип	
	а		по		дороге		#		услышал		стук	

Метрики оценки качества транскрибации




$d(S_1, S_2) = D(M, N)$, где

$$D(i, j) = \begin{cases} 0 & ; i = 0, j = 0 \\ i * \text{deleteCost} & ; j = 0, i > 0 \\ j * \text{insertCost} & ; i = 0, j > 0 \\ D(i - 1, j - 1) & ; S_1[i] = S_2[j] \\ \min (& \\ \quad D(i, j - 1) + \text{insertCost} & \\ \quad D(i - 1, j) + \text{deleteCost} & \\ \quad D(i - 1, j - 1) + \text{replaceCost} & \\) & ; j > 0, i > 0, S_1[i] \neq S_2[j] \end{cases}$$

$$\text{WER} = \frac{S + I + D}{N}$$


Постановка задачи ASR



Задача выравнивания последовательностей (АКА Seq2Seq)


Давайте сегментируем запись и отправим в разметку?

Будем
классифицировать
каждый чанк ?




Давайте сегментируем запись и отправим в разметку?

- Дорого
- Сложно
- Нужно много данных
- Очень неустойчивый подход




Sequence alignment

Модель должна сама
понять, какой участок
аудио относится к
каждому звуку/слову



Back in 2006: Connectionist Temporal Classification





СТС

В-преобразование - удаление
повторов и <BLANK>

логиты ($|V| \times \text{seq_len}$)

контекстно
независимый декодер

скрытое
представление



Зачем нужен <BLANK> (|) токен

п	р	и	и	в	в	е	е	е	т				→	привет
к	и	и	л	о	о	г	р	а	м	м	м		→	килограмм
к	и	и	л	о	о	г	р	а	м	м		м	→	килограмм

В-преобразование: сначала убираем дубликаты букв, затем удаляем <blank>.




Как обучать?
Где взять GT?

СТС


Максимизируем все $P(\text{гипотезы}|\text{спектрограммы})$, где гипотезы приводят к GT

CTC Loss

$$L = \min -\log(P(Y|X))$$




Матрица логитов ($|V| \times \text{seq_len}$). Возможный
правильный путь.




$$P(|\text{приивееет}|) = y_{|}^1 \cdot y_{\text{п}}^2 \cdot y_{\text{р}}^3 \cdot y_{\text{и}}^4 \cdot y_{\text{и}}^5 \cdot y_{\text{и}}^6 \cdot y_{\text{в}}^7 \cdot y_{\text{е}}^8 \cdot y_{\text{е}}^9 \cdot y_{\text{е}}^{10} \cdot y_{\text{т}}^{11} \cdot y_{|}^{12}$$

Матрица логитов ($|V| \times \text{seq_len}$). Возможный
правильный путь.



$$P(|||||привет) = y_{|}^1 \cdot y_{|}^2 \cdot y_{|}^3 \cdot y_{|}^4 \cdot y_{|}^5 \cdot y_{|}^6 \cdot y_{п}^7 \cdot y_{р}^8 \cdot y_{и}^9 \cdot y_{в}^{10} \cdot y_{е}^{11} \cdot y_{т}^{12}$$


Матрица логитов ($|V| \times \text{seq_len}$). Возможный
правильный путь.



$$P(\text{приивет}|||'|) = y_{\text{п}}^1 \cdot y_{\text{р}}^2 \cdot y_{\text{и}}^3 \cdot y_{\text{и}}^4 \cdot y_{\text{в}}^5 \cdot y_{\text{е}}^6 \cdot y_{\text{т}}^7 \cdot y_{|}^8 \cdot y_{|}^9 \cdot y_{|}^{10} \cdot y_{|}^{11} \cdot y_{|}^{12}$$


CTC Loss

$$P(\text{привет}) = P(|\text{прииивееет}|) + P(|||||привет) + P(\text{приивет}|||) + \dots$$



Множество всех возможных путей

B



Множество всех возможных гипотез

CTC Loss

$$\mathcal{L}(X, R) = -\log \sum_{C \in B^{-1}(R)} P(C|X) = -\log \sum_{C \in B^{-1}(R)} \prod_{t=1}^T p(c_t|X)$$

спектрограмма GT гипотеза гипотезы для которых $R = B(C)$

$|V| = 7$, $seq\ len = 12$, $possible\ paths = 7^{12} \sim 14B$

[Как считать CTC лосс эффективно](#)


CTC Loss Summary

- Контекстно независимые предсказания
- Можем предсказывать параллельно для каждого hidden
- Не склонен к бредогенерации
- Если $\text{len}(\text{text}) > \text{len}(\text{encoder hidden})$ - никогда не предскажем корректную гипотезу

Дополнительно про CTC Loss

- [CTC paper](#)
- [Connectionist Temporal Classification Loss](#)
- [Sequence Modeling With CTC](#)

Encoders




Энкодеры. Бенчмарки для сравнения.

- [Librispeech](#) ~1k часов аудиокниг
- [WSJ](#) ~80 часов (чтение текста из Wall Street Journal)
- [Лидерборд моделей на HF](#)

Read Speech			
Test set	DS1	DS2	Human
WSJ eval'92	4.94	3.60	5.03
WSJ eval'93	6.94	4.98	8.08
LibriSpeech test-clean	7.89	5.33	5.83
LibriSpeech test-other	21.74	13.25	12.69

Deep Speech 2

Read Speech			
Test set	DS1	DS2	Human
WSJ eval'92	4.94	3.60	5.03
WSJ eval'93	6.94	4.98	8.08
LibriSpeech test-clean	7.89	5.33	5.83
LibriSpeech test-other	21.74	13.25	12.69



Jasper

Доклад ODS

Table 5: LibriSpeech, WER (%)

Model	E2E	LM	dev-clean	dev-other	test-clean	test-other
CAPIO (single) [23]	N	RNN	3.02	8.28	3.56	8.58
pFSMN-Chain [25]	N	RNN	2.56	7.47	2.97	7.5
DeepSpeech2 [26]	Y	5-gram	-	-	5.33	13.25
Deep bLSTM w/ attention [21]	Y	LSTM	3.54	11.52	3.82	12.76
wav2letter++ [27]	Y	ConvLM	3.16	10.05	3.44	11.24
LAS + SpecAugment ⁴ [28]	Y	RNN	-	-	2.5	5.8
Jasper DR 10x5	Y	-	3.64	11.89	3.86	11.95
Jasper DR 10x5	Y	6-gram	2.89	9.53	3.34	9.62
Jasper DR 10x5	Y	Transformer-XL	2.68	8.62	2.95	8.79
Jasper DR 10x5 + Time/Freq Masks ⁴	Y	Transformer-XL	2.62	7.61	2.84	7.84






Figure 1: Jasper $B \times R$ model: B - number of blocks, R - number of sub-blocks.

Conformer




Method	#Params (M)	WER Without LM		WER With LM	
		testclean	testother	testclean	testother
Hybrid					
Transformer [33]	-	-	-	2.26	4.85
CTC					
QuartzNet [9]	19	3.90	11.28	2.69	7.25
LAS					
Transformer [34]	270	2.89	6.98	2.33	5.17
Transformer [19]	-	2.2	5.6	2.6	5.7
LSTM	360	2.6	6.0	2.2	5.2
Transducer					
Transformer [7]	139	2.4	5.6	2.0	4.6
ContextNet(S) [10]	10.8	2.9	7.0	2.3	5.5
ContextNet(M) [10]	31.4	2.4	5.4	2.0	4.5
ContextNet(L) [10]	112.7	2.1	4.6	1.9	4.1
Conformer (Ours)					
Conformer(S)	10.3	2.7	6.3	2.1	5.0
Conformer(M)	30.7	2.3	5.0	2.0	4.3
Conformer(L)	118.8	2.1	4.3	1.9	3.9

Дополнительно по теме:

- [Golos - датасет бенчмарк на русском](#)
- [OpenSTT - русскоязычные датасеты и бенчмарки](#)
- [Swish activation](#)
- [GLU activation](#)
- [Macaron net](#)
- [Depthwise convolution](#)
- [Librispeech LB](#)

Decoding



Greedy decoding


<blank>	0.6	0.7
a	0.4	0.3
b	0.4	0.5

$$P("") = 0.7 * 0.6 = 0.42$$

$$P(a) = P(aa) + P(a|) + P(a|) = 0.4 * 0.3 + 0.6 * 0.3 + 0.2 * 0.7 = 0.44$$

$P(a) > P("")$, но при жадном декодировании мы этого никогда не узнаем

Beam Search Decoding




Итоги по CTC


- Основная метрика качества в ASR – WER
- В CTC мы не знаем, где начинается и заканчивается символ.
Максимизируем суммарную вероятность всех возможных вариантов предсказания, приводящих к правильному результату после В-трансформации.
- Декодирование:
 - контекстно независимое,
 - Beam-Search алгоритм для эффективного составление предсказания.

Listen, Attend and Spell (LAS)

Идея: seq-to-seq модель



Listen, Attend and Spell




← декодер

$$c_i = \text{AttentionContext}(s_i, \mathbf{h})$$

$$s_i = \text{RNN}(s_{i-1}, y_{i-1}, c_{i-1})$$


$$P(y_i | \mathbf{x}, y_{<i}) = \text{CharacterDistribution}(s_i, c_i)$$



← энкодер

BiLSTM сжимающие
временную размерность


Listen, Attend and Spell



$$P(\mathbf{y}|\mathbf{x}) = \prod_i P(y_i|\mathbf{x}, y_{<i})$$

Теперь декодер контекстно
зависимый
Какой здесь лосс?

Listen, Attend and Spell




$$P(\mathbf{y}|\mathbf{x}) = \prod_i P(y_i|\mathbf{x}, y_{<i})$$


Оптимизируется кросс
энтропия

$$L_{CE} = \sum CE_i$$

Teacher forcing VS Autoregressive Predictions




GT: `<sos>` я есть грут



GT: `<sos>` я есть грут

А где
трансформеры?



Whisper

Основные идеи:

- Хотим получить супер классную модель, которая работает в zero-shot режиме одинаково хорошо на разных доменах
- Чем больше данных из разных доменов, тем будет лучше генерализация модели
- Сложно собрать большой сет данных, давайте собирать weakly supervised data (680K hours up to 3M hours)
- Растим модель, растим датасет
- Обучаем модель в мультитаск режиме (сразу несколько задач), это помогает сделать ее устойчивой к доменному сдвигу

Whisper

Multitask training data (680k hours)

English transcription

- “Ask not what your country can do for ...”
- Ask not what your country can do for ...

Any-to-English speech translation

- “El rápido zorro marrón salta sobre ...”
- The quick brown fox jumps over ...


Non-English transcription

- “언덕 위에 올라 내려다보면 너무나 넓고 넓은 ...”
- 언덕 위에 올라 내려다보면 너무나 넓고 넓은 ...


No speech

- (background music playing)
- ∅

Sequence-to-sequence learning



Whisper Token format



Model	Layers	Width	Heads	Parameters
Tiny	4	384	6	39M
Base	6	512	8	74M
Small	12	768	12	244M
Medium	24	1024	16	769M
Large	32	1280	20	1550M

Table 1. Architecture details of the Whisper model family.

Whisper Results




Figure 2. Zero-shot Whisper models close the gap to human robustness. Despite matching or outperforming a human on LibriSpeech dev-clean, supervised LibriSpeech models make roughly twice as many errors as a human on other datasets demonstrating their brittleness and lack of robustness. The estimated robustness frontier of zero-shot Whisper models, however, includes the 95% confidence interval for this particular human.


Dataset	wav2vec 2.0 Large (no LM)	Whisper Large V2	RER (%)
LibriSpeech Clean	2.7	2.7	0.0
Artie	24.5	6.2	74.7
Common Voice	29.9	9.0	69.9
Fleurs En	14.6	4.4	69.9
Tedlium	10.5	4.0	61.9
CHiME6	65.8	25.5	61.2
VoxPopuli En	17.9	7.3	59.2
CORAAL	35.6	16.2	54.5
AMI IHM	37.0	16.9	54.3
Switchboard	28.3	13.8	51.2
CallHome	34.8	17.6	49.4
WSJ	7.7	3.9	49.4
AMI SDM1	67.6	36.4	46.2
LibriSpeech Other	6.2	5.2	16.1
Average	29.3	12.8	55.2

Table 2. Detailed comparison of effective robustness across various datasets. Although both models perform within 0.1% of each other on LibriSpeech, a zero-shot Whisper model performs much better on other datasets than expected for its LibriSpeech performance and makes 55.2% less errors on average. Results reported in word error rate (WER) for both models after applying our text normalizer.


the smallest zero-shot Whisper model, which has only 39

Как улучшить ASR
без такого огромного
кол-ва данных?


Как на счет
дистилляции
моделей?



Hard distillation



Distillation by embeddings




Маленькая модель (student) учится предсказывать эмбединги, предсказанные большой моделью (teacher).

$$\text{Loss} = \text{CE} + \text{L2}(\text{student hiddens} - \text{teacher hiddens})$$

Можем ли как-то
использовать
языковые модели
(LM)?

Second Pass Rescoring

$$\mathbf{y}^* = \arg \max_{\mathbf{y}} \log P(\mathbf{y}|\mathbf{x}) + \lambda \log P_{LM}(\mathbf{y}) + \gamma \text{len}(\mathbf{y})$$



$P_{LM}(\text{“мама мыла раму”}) = 0.25$

$P_{LM}(\text{“мама ыла рму”}) = 0.0001$

hypos:

мама мыла раму


мама ыла рму

мамамамама

мыла рамума


GT: мама мыла раму

First Pass Rescoring



$$y_i^* = \underset{y_i}{\operatorname{argmax}} P_{ASR}(y_i | x, y_{<i}) + \lambda P_{LM}(y_i | y_{<i})$$

Что сейчас в
тренде? Что еще
посмотреть?



Что еще посмотреть

- Курс по LLM и ASR: <https://web.stanford.edu/~jurafsky/slp3/>
- [Доклад по CTC \(Яндекс\)](#)
- [Wav2Vec2.0](#)
- Decoder LLM <https://arxiv.org/pdf/2402.08846v1>
- RNN-t

- Библиотеки: torchaudio (трансформации), librosa (аугментация)
- [Лидерборд моделей на HF](#)
- Соревнования на kaggle:
<https://www.kaggle.com/competitions/bengaliai-speech>

Спасибо за
внимание!